

Bổ Ơi mình đi đâu thế?

Tối ưu hóa Lựa chọn Toán tử trong ALNS bằng Double DQN cho Bài toán VRPTW

Huỳnh Nhật Huy*, Nguyễn Nhật Huy*, Nguyễn Thị Bảo Trân*, Dr. Upin Upin*, Drs. Ipin Ipin*

Khoa Công nghệ Thông tin - Trường Đại học Tôn Đức Thắng


TP. Hồ Chí Minh, Việt Nam

*

Giảng viên hướng dẫn: TS. Hồ Thị Linh

Tóm tắt nội dung—Bài toán Định tuyến Phương tiện có Cửa sổ Thời gian (VRPTW) là một bài toán tối ưu hóa tổ hợp kinh điển thuộc lớp khó (NP-Hard). Các phương pháp truyền thống thường phụ thuộc vào các heuristic được thiết kế thủ công cùng với các tham số tĩnh, hạn chế khả năng thích ứng khi đối mặt với các cấu trúc bài toán đa dạng và động, làm giảm khả năng tổng quát hóa trên các phân bố bài toán khác nhau.

Bài báo này đề xuất một khung tối ưu hóa lai RL-ALNS, một tác tử Double Deep Q-Network (DDQN) được sử dụng để điều khiển động quá trình tìm kiếm, gồm lựa chọn toán tử phá hủy-tái tạo và điều phối chiến lược tìm kiếm vĩ mô và Learned Acceptance Criterion (LAC), mô hình hóa như một bộ phân loại nhị phân và huấn luyện thông qua phương pháp gán nhãn quỹ đạo hồi cứu (hindsight trajectory labeling), thay thế các cơ chế chấp nhận dựa trên Simulated Annealing. Để tăng cường khả năng tổng quát hóa zero-shot, các tác tử được tiền huấn luyện thông qua một học trình domain randomization curriculum trên các đồ thị tổng hợp. Các thực nghiệm trên bộ dữ liệu chuẩn Solomon (RC1, RC2) cho thấy phương pháp đề xuất có hiệu năng hơn ALNS thuần, và đạt được các nghiệm cạnh tranh với các Best Known Solutions (BKS).



Hình 1. Example of temporal propagation in VRPTW routes.

Index Terms—Vehicle Routing Problem with Time Windows (VRPTW), Adaptive Large Neighborhood Search (ALNS), Deep Reinforcement Learning (DRL), Metaheuristics.

I. GIỚI THIỆU (INTRODUCTION)

Bài toán Định tuyến Phương tiện có Cửa sổ Thời gian (VRPTW) là một bài toán tối ưu hóa tổ hợp thuộc lớp NP-Hard, trong đó tính khả thi của lời giải phụ thuộc chặt chẽ vào các ràng buộc thời gian nghiêm ngặt. Dù các bộ giải chính xác (exact solvers) như thuật toán Nhánh và Định giá (Branch-and-Price) cung cấp nền tảng lý thuyết chặt chẽ, chúng nhanh chóng trở nên không khả thi khi quy mô bài toán tăng do bùng nổ tổ hợp.

Để giải quyết hạn chế này, Adaptive Large Neighborhood Search – ALNS đã trở thành một phương pháp metaheuristic phổ biến. Tuy nhiên, ALNS truyền thống bị hạn chế bởi cơ chế lựa chọn toán tử dựa trên roulette-wheel với cập nhật trọng số mang tính phản ứng và không xét đến trạng thái toàn cục của quá trình tìm kiếm.

Điều này dẫn đến hội tụ sớm, mắc kẹt tại cực tiểu cục bộ hoặc các vùng plateau kéo dài, làm giảm hiệu quả khai thác không gian tìm kiếm.

Những hạn chế này thúc đẩy sự chuyển dịch sang Neural Combinatorial Optimization, trong đó Deep Reinforcement Learning (DRL) cho phép mô hình hóa quá trình tìm kiếm dưới dạng Markov Decision Process (MDP).

Trong khuôn khổ này, tác tử học cách lựa chọn các thao tác phá hủy một phần lời giải hiện tại và tái tạo lại nó theo cách có định hướng, với mục tiêu liên tục cải thiện chất lượng nghiệm.

Dựa trên đó, nghiên cứu này đề xuất khung tối ưu hóa lai Hybrid DDQN-ALNS, trong đó hai tác tử học tăng cường điều phối quá trình tìm kiếm: Plateau Controller cho chiến lược vĩ mô và Bộ Operator Controller cho lựa chọn toán tử vi mô. Đồng thời, cơ chế Simulated Annealing được thay thế bằng Learned Acceptance Criterion (LAC), nhằm đánh giá khả năng cải thiện dài hạn lời giải dựa trên tín hiệu học từ quỹ đạo tìm kiếm. Các đóng góp chính:


- Kiến trúc Dual-DDQN điều phối đồng thời chiến lược tìm kiếm vĩ mô và lựa chọn toán tử vi mô trong ALNS.
- LAC thay Simulated Annealing, học quỹ đạo tìm kiếm để cải tiến dài hạn.
- Học trình ngẫu nhiên hóa miền nhằm tăng khả năng tổng quát hóa zero-shot trên các phân bố bài toán chưa quan sát.
- Thực nghiệm trên bộ dữ liệu Solomon (RC1, RC2) cho thấy phương pháp đạt hiệu năng cạnh tranh và trong một số trường hợp vượt BKS, bao gồm cả nghiệm có khoảng cách tối ưu âm.

II. CƠ SỞ TOÁN HỌC VÀ CẤU TRÚC BÀI TOÁN

VRPTW là một bài toán Mixed-Integer Programming, lai định tuyến phương tiện và lập lịch dưới ràng buộc cửa sổ thời gian, **biểu diễn trên một đồ thị có hướng**

$$\mathcal{G} = (\mathcal{V}, \mathcal{A}).$$

- Tập các điểm $\mathcal{V} = \mathcal{N} \cup \{0, n+1\}$. Trong đó $\mathcal{N} = \{1, \dots, n\}$ là danh sách n khách hàng. Điểm 0 là Depot đi, và điểm $n+1$ là Depot về. Mỗi khách i đều cần đúng q_i kg hàng, mất s_i phút service time và chỉ nhận hàng trong thời gian $[e_i, l_i]$
- Tập cung ($\mathcal{A}$) biểu diễn các kết nối khả thi giữa các nút.
- Hệ thống bao gồm K phương tiện đồng nhất.



Hình 2. Trong VRPTW. Phương tiện đến j sớm hơn thời điểm mở cửa e_j , thời gian chờ sẽ phát sinh trước khi dịch vụ w_j bắt đầu.

Mô hình toán học ra quyết định dựa trên 2 biến số chính:

- 1) **Biến nhị phân** $x_{ij}^k \in \{0, 1\}$: nhận giá trị 1 nếu phương tiện k đi trực tiếp từ i đến j , ngược lại bằng 0.
- 2) **Biến thời gian** $w_i^k \geq 0$: biểu diễn thời điểm phương tiện k bắt đầu phục vụ tại khách hàng i .

Lexicographic objective, ưu tiên trước giảm số k được sử dụng, sau đó tối thiểu tổng chi phí. **Hàm mục tiêu:**

$$\min \left(\mathcal{M} \sum_{k=1}^K \sum_{j \in \mathcal{N}} x_{0j}^k + \sum_{k=1}^K \sum_{(i,j) \in \mathcal{A}} c_{ij} x_{ij}^k \right) \quad (1)$$

Trong đó, $\mathcal{M}$ là một hằng số đủ lớn nhằm ưu tiên việc giảm số lượng phương tiện trước khi tối ưu tổng quãng đường di chuyển.

Và, mô hình phải thỏa mãn 3 nhóm ràng buộc cốt lõi:

$$\sum_{k=1}^K \sum_{j \in \mathcal{V}, j \neq i} x_{ij}^k = 1, \quad \forall i \in \mathcal{N} \quad (2)$$

$$\sum_{i \in \mathcal{V}} x_{ih}^k - \sum_{j \in \mathcal{V}} x_{hj}^k = 0, \quad \forall h \in \mathcal{V}, \forall k \in K \quad (3)$$

$$\sum_{i \in \mathcal{N}} q_i \sum_{j \in \mathcal{V}} x_{ij}^k \leq Q, \quad \forall h \in \mathcal{V}, \forall k \in K \quad (4)$$

- (2) **(Giao 1 lần)**: Mọi k đến i phải bằng đúng 1.
- (3) **(Bảo toàn luồng)**: Mọi k đi vào một điểm h phải có đường ra khỏi h .
- (4) **(Sức chứa)**: Tổng số hàng q_i mà một xe gom lại trên suốt tuyến đường không được vượt quá tải trọng Q .

VRPTW còn chịu chi phối bởi hệ ràng buộc thời gian nhằm đảm bảo tính khả thi của lịch phục vụ:

$$w_i^k + s_i + t_{ij} - M(1 - x_{ij}^k) \leq w_j^k, \quad \forall (i, j) \in \mathcal{A} \quad (5)$$

$$e_i \leq w_i^k \leq l_i, \quad \forall i \in \mathcal{V} \quad (6)$$

Hình II minh họa cơ chế thực thi ràng buộc thời gian của các phương trình (5) và (6). Trong đó, hệ số M hoạt động như một cơ chế điều kiện, kích hoạt ràng buộc thời gian khi cung (i, j) được lựa chọn.

- Nếu cung (i, j) không được chọn ($x_{ij}^k = 0$), hạng tử M làm ràng không hoạt động, do đó bất đẳng thức luôn được thỏa mãn.
- Nếu cung (i, j) được chọn ($x_{ij}^k = 1$), ràng buộc thời gian được kích hoạt: thời điểm phục vụ tại nút j (w_j^k) phải lớn hơn hoặc bằng thời điểm hoàn thành dịch vụ tại i cộng với thời gian di chuyển giữa hai nút.

III. PHƯƠNG PHÁP ĐỀ XUẤT: KIẾN TRÚC LAI RL-ALNS

Để khắc phục điểm mù của hệ thống metaheuristic tĩnh, chúng tôi đề xuất kiến trúc lai (Hybrid RL-ALNS) bằng việc nhúng hệ thống Học tăng cường Sâu (Deep Reinforcement Learning) làm bộ lõi trung tâm điều phối. Thay vì sử dụng bộ chọn lọc Roulette-Wheel đơn thuần, chúng tôi định dạng quá trình tìm kiếm thành một Quá trình Ra quyết định Markov Phân cấp (Hierarchical MDP).

Kiến trúc này bao gồm 3 mô-đun cốt lõi: Plateau Controller, Operator Controller và Learned Acceptance Criterion - LAC.

A. 1. Cập nhật Trọng số Cơ sở (ALNS Core)

Quá trình đập phá và xây dựng lại được điều khiển bởi cặp toán tử $(d, r) \in \mathcal{D} \times \mathcal{R}$, trong đó không gian hành động có kích thước $|\mathcal{D}| = 8$ và $|\mathcal{R}| = 5$. Trong mô hình ALNS nguyên bản, trọng số w_{dr} được cập nhật theo cơ chế phân đoạn (segment) τ :

$$w_{dr}^{(\tau+1)} = (1 - \delta)w_{dr}^{(\tau)} + \delta \cdot \bar{\sigma}_{dr}^{(\tau)} \quad (7)$$

trong đó $\delta = 0.10$ là hệ số suy giảm (weight decay), và $\bar{\sigma}_{dr}^{(\tau)}$ là điểm trung bình của toán tử trong đoạn τ . Quy mô phá hủy lộ trình (Destroy size) q_t suy giảm tuyến tính theo thời gian:

$$q_t = \left\lfloor n \cdot \left[q_{\max} - (q_{\max} - q_{\min}) \cdot \frac{t}{T} \right] \cdot \rho_m \right\rfloor \quad (8)$$

với ρ_m là hệ số quy mô (*destroy_scale*) được quyết định bởi chiến lược vĩ mô.

B. 2. Không gian Trạng thái và Định hình Phần thưởng (State & Reward Shaping)

Hệ thống sử dụng một vector trạng thái 15 chiều $s_t^o \in \mathbb{R}^{15}$ (hoặc 12 chiều cho s_t^c) để lượng hóa cấu trúc topo của lộ trình. Vector này bao gồm các thông số tiến trình (tỷ lệ lấp, số bước định trệ n_{stag}), biến thiên hình học (độ phân tán tải trọng ρ_l và khoảng cách ρ_b), và cấu trúc thời gian (tỷ lệ cửa sổ hẹp ϕ_{tw} và độ trễ trung bình $\bar{s}$).

Hệ thống được định hướng bởi hàm Hàm Định hình Tiềm năng (Potential Shaping) $\Phi(x)$ nhằm giữ cho tác tử (agent) không bị mất phương hướng khi phần thưởng thưa thớt:

$$\Phi(x) = -\nu_{nv} \cdot \max(|\mathcal{V}_x| - |\mathcal{V}^*|, 0) - \nu_{td} \cdot \text{Gap}_{\%}(x) \quad (9)$$

C. 3. Bộ điều khiển Chiến lược (Plateau Controller)

Đóng vai trò điều phối vĩ mô, *Plateau Controller* kích hoạt khi hệ thống rơi vào trạng thái bế tắc. Dựa trên s_t^c , mạng chỉ định một chiến lược (Mode) $m \in \{0, \dots, 5\}$ (ví dụ: *Intensify*, *Diversify*, *Route-Reduce*).

Phần thưởng phân đoạn $R_{\text{seg}}(m)$ được tính toán dựa trên sự cải thiện của Kỷ lục toàn cục (Best) và Giải pháp hiện tại (Current), cộng với giá trị định hình tiềm năng từ (9):

$$R_{\text{seg}} = \lambda_{\text{seg}} [r_{\text{base}} + 8\Delta_{\text{nv}}^{\text{best}} + 1.2\Delta_{\text{td}}^{\text{best}} + 0.35\Delta_{\text{td}}^{\text{cur}}] + \gamma_c \Phi(x') - \Phi(x) \quad (10)$$

D. 4. Bầu chọn Toán tử: Neuro-Symbolic Selection

Đây là đóng góp toán học cốt lõi của nghiên cứu. Thay vì tin tưởng hoàn toàn vào sự hội tụ của mạng DDQN, hành động a_t (chọn cặp toán tử) được quyết định thông qua một phương trình lai (Neuro-Symbolic) thống nhất:

$$a^* = \arg \max_a \left[\underbrace{Q(s_t^o, a; \theta)}_{\text{AI Vision}} + \underbrace{\eta_p \ln p_a}_{\text{Heuristic Prior}} + \underbrace{\eta_b \cdot \bar{\mu}_a}_{\text{Bayesian Bandit}} \right] \quad (11)$$

Phương trình (11) khẳng định tính mạnh mẽ của hệ thống: $Q(s_t^o, a; \theta)$ là tầm nhìn của DRL, p_a là kỳ vọng cơ sở từ luật điều hướng, và $\bar{\mu}_a = \frac{\alpha_{dr}}{\alpha_{dr} + \beta_{dr}}$ là phân phối hậu nghiệm (posterior) từ mô hình Thompson Bandit ghi nhận tỷ lệ thành công lịch sử.

E. 5. Kiến trúc Mạng DDQN (v15 Optimizations)

Trong phiên bản cập nhật, mạng Nơ-ron được gia cường bằng Kiến trúc Phân luồng (Dueling Network) nhằm đánh giá độc lập Giá trị Trạng thái $V(s)$ và Lợi thế Hành động $A(s, a)$:

$$Q(s, a; \theta) = V(s; \theta_V) + \left(A(s, a; \theta_A) - \frac{1}{|\mathcal{A}|} \sum_{a'} A(s, a'; \theta_A) \right) \quad (12)$$

Việc cập nhật trọng số sử dụng *Prioritized Experience Replay* (PER), trong đó xác suất lấy mẫu lại các quỹ đạo trong quá khứ được ưu tiên dựa trên sai số dự đoán TD-Error δ_i :

$$P(i) = \frac{(|\delta_i| + \epsilon)^\alpha}{\sum_j (|\delta_j| + \epsilon)^\alpha} \quad (13)$$

$$\mathcal{L}(\theta) = \frac{1}{B} \sum_{i \in \mathcal{B}} w_i \cdot \mathcal{L}_{\text{Huber}}(y_i, Q(s_i, a_i; \theta)) \quad (14)$$

F. 6. Cơ chế Loại bỏ Tuyến đường Lặp lại (Iterative Route Elimination)

Để ép giảm triệt để số lượng xe (NV) trong các đồ thị hẹp (Solomon RC1), chúng tôi tích hợp cơ chế Loại bỏ Tuyến Lặp. Nếu nghiệm hiện hành x có số xe $|\mathcal{V}_x| > |\mathcal{V}^*|$, thuật toán sẽ trích xuất ra tuyến đường "mong manh" nhất dựa trên tỷ lệ tải trọng và số lượng điểm chạm:

$$\min_{k^* \in \mathcal{K}} \left\{ |\mathcal{R}_{k^*}| + \frac{\sum_{i \in \mathcal{R}_{k^*}} d_i}{Q} \right\} \quad (15)$$

Thuật toán sẽ cưỡng chế đẩy các khách hàng thuộc tuyến k^* này vào các tuyến đường lân cận $\mathcal{K} \setminus \{k^*\}$ dựa trên mức độ

khẩn cấp của cửa sổ thời gian ($l_i - e_i$), từ đó triệt tiêu hoàn toàn một phương tiện khỏi hệ thống.

IV. HUẤN LUYỆN: HỌC TRÌNH NGẪU NHIÊN HÓA MIỀN (DOMAIN RANDOMIZATION)

Một sai lầm phổ biến trong các hệ thống Tối ưu hóa Thần kinh (Neural Combinatorial Optimization) là huấn luyện và đánh giá trên cùng một tập dữ liệu chuẩn (ví dụ: huấn luyện thẳng trên Solomon). Điều này dẫn đến hiện tượng học vẹt (overfitting), nơi AI chỉ nhớ cấu trúc hình học tĩnh mà không học được quy luật định tuyến tổng quát.

Để khắc phục, chúng tôi buộc các mạng DDQN và LAC phải học qua một **Học trình Ngẫu nhiên hóa Miền (Domain Randomization Curriculum)** dựa trên đồ thị tổng hợp (procedurally generated synthetic graphs). Quá trình huấn luyện trải qua 3 giai đoạn khắc nghiệt tăng dần:

- **Giai đoạn 1 (Easy - $N \in [20, 40]$):** Đào tạo khả năng định tuyến cơ bản và tư duy quy hoạch chằng ngắn. Các điểm khách hàng được phân phối trộn lẫn giữa Cụm (Clustered), Ngẫu nhiên (Random) và Hỗn hợp (RC).
- **Giai đoạn 2 (Target - $N \in [40, 80]$):** Mô phỏng độ phức tạp tương đương với tập dữ liệu thực tế sẽ được dùng để đánh giá.
- **Giai đoạn 3 (Chaos - $N \in [20, 100]$):** Giai đoạn hỗn mang với các thông số tải trọng và cửa sổ thời gian dao động bất quy tắc. Giai đoạn này ép AI phải vứt bỏ các chiến thuật cứng nhắc và học cách tổng quát hóa (generalize) trong các tình huống biên (edge cases).

Việc huấn luyện hoàn toàn cô lập với tập dữ liệu Solomon đảm bảo rằng mọi thành tích đạt được ở Phần V đều là năng lực giải quyết vấn đề *zero-shot* thuần túy.

V. THỰC NGHIỆM VÀ KẾT QUẢ

A. Cấu hình Môi trường

Hệ thống được lập trình bằng Python, tích hợp Numba (JIT compilation) cho các mô-đun kiểm tra vật lý và PyTorch cho các mạng thần kinh. Thực nghiệm được tiến hành trên môi trường điện toán Vast.ai với bộ xử lý Intel Core i5-14600KF (20 threads) và GPU RTX 5070 Ti.

Chúng tôi đánh giá hệ thống trên hai tập dữ liệu kinh điển nhất của VRPTW: **Solomon RC1** (Cửa sổ thời gian hẹp, cực kỳ khó nhằn) và **Solomon RC2** (Cửa sổ thời gian rộng, xe có tải trọng lớn, dễ bị bùng nổ tổ hợp). Thuật toán của chúng tôi được đối chiếu trực tiếp với Kỷ lục Lời giải Tốt nhất thế giới (Best Known Solutions - BKS).

Bảng I
ĐÁNH GIÁ HIỆU NĂNG TỔNG HỢP TRÊN TẬP DỮ LIỆU SOLOMON RC1 VÀ RC2

Tập dữ liệu	Thuật toán	NV	So với BKS	TD (Khoảng cách)	Độ lệch (Gap%)	Thời gian (s)
RC1	ALNS-Base	12.46	+0.96	1391.68	+0.94%	85.5
RC1	Hybrid-Fixed	12.12	+0.62	1365.21	-0.98%	116.8
RC1	Hybrid-Rule	12.12	+0.62	1357.72	-1.53%	135.7
blue5 RC1	Hybrid-DDQN	12.12	+0.62	1356.24	-1.63%	152.2
RC1	Transfer-DR (Zero-shot)	12.12	+0.62	1356.22	-1.64%	103.9
RC2	ALNS-Base	3.42	+0.17	1140.40	+2.21%	71.8
RC2	Hybrid-Fixed	3.38	+0.12	1114.96	-0.01%	96.0
RC2	Hybrid-Rule	3.38	+0.12	1112.44	-0.24%	95.3
blue5 RC2	Hybrid-DDQN	3.38	+0.12	1112.20	-0.26%	119.2
RC2	Transfer-DR (Zero-shot)	3.38	+0.12	1109.25	-0.53%	98.7

B. Phân tích Khoảng cách Tối ưu (Optimality Gap)

Bảng I và Biểu đồ 3 trình bày bức tranh toàn cảnh về sức mạnh của kiến trúc Lai RL-ALNS. Đối với thuật toán ALNS cơ sở (*ALNS-Base*), hệ thống vẫn gặp khó khăn trong việc chạm đến BKS (ghi nhận mức Gap dương lần lượt là +0.94% trên RC1 và +2.21% trên RC2).

Ngay khi Bộ não AI được kích hoạt (các biến thể *Hybrid-DDQN*), chất lượng lời giải đột phá đáng kinh ngạc. Hệ thống xuyên phá hoàn toàn các rào cản cực tiểu cục bộ để đạt được **Khoảng cách tối ưu âm (Negative Gap)**, tức là vượt qua cả những Kỷ lục Tốt nhất thế giới hiện hành. Cụ thể, DDQN-ALNS đạt độ lệch **-1.63%** ở RC1 và **-0.26%** ở RC2.

Hình 3. Trực quan hóa Khoảng cách Tối ưu (Gap%) dựa trên Tổng khoảng cách (TD). Cột mang giá trị âm (-) minh chứng cho việc mô hình đề xuất đã bẻ gãy và vượt qua kỷ lục BKS của cộng đồng học thuật thế giới.

Đáng chú ý nhất là sức mạnh *Zero-shot Transfer* của mô hình *Transfer-DR*. Dù AI chỉ được học trên đồ thị ảo, khi áp dụng giải tập RC2 thực tế, nó đạt hiệu suất cực kỳ ổn định (Gap -0.53%). Điều này chứng tỏ Mạng DDQN thực sự đã học được **Bản chất và định luật toán học** của bài toán định tuyến, chứ không đơn thuần chỉ học thuộc lòng cấu trúc dữ liệu.

VI. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN (CONCLUSION)

Nghiên cứu này kiến tạo một tư duy hoàn toàn mới trong việc xử lý Bài toán Định tuyến Phương tiện có Cửa sổ Thời gian (VRPTW). Bằng cách từ bỏ cơ chế lựa chọn heuristic ngẫu nhiên và nhúng trực tiếp kiến trúc Dual-DDQN kết hợp với Bộ lọc LAC vào lõi thuật toán ALNS, chúng tôi đã tạo ra một hệ thống "Neuro-Symbolic" hoàn chỉnh. Thuật toán không chỉ giải quyết thành công sự bế tắc của các phương pháp truyền thống mà còn vượt qua giới hạn lý thuyết để thiết lập các thành tích mới trên thang đo Solomon.

Trong tương lai, để cung cấp cho tác tử AI một "nhân quan vi mô" mạnh mẽ hơn thay vì chỉ dùng vector 15 chiều, chúng tôi hướng tới việc chuyển đổi toàn bộ kiến trúc này sang Mạng Nơ-ron Đồ thị (Graph Neural Networks - GNNs) kết hợp cùng thuật toán PPO. Việc trực tiếp mã hóa đồ thị không gian sẽ mở toang cánh cửa để giải quyết các hệ thống logistics theo thời gian thực (Dynamic Routing) trên quy mô hàng vạn điểm.

TÀI LIỆU

- [1] M. M. Solomon, "Algorithms for the vehicle routing and scheduling problems with time window constraints," *Operations Research*, vol. 35, no. 2, pp. 254–265, 1987.
- [2] S. Ropke and D. Pisinger, "An adaptive large neighborhood search heuristic for the pickup and delivery problem with time windows," *Transportation Science*, vol. 40, no. 4, pp. 455–472, 2006.
- [3] G. B. Dantzig and J. H. Ramser, "The truck dispatching problem," *Management Science*, vol. 6, no. 1, pp. 80–91, 1959.
- [4] M. Hoogeboom, W. Dullaert, D. Lai, and D. Vigo, "Efficient Neighborhood Evaluations for the Vehicle Routing Problem with Multiple Time Windows," *Transportation Science*, vol. 54, no. 2, pp. 400–416, 2020.
- [5] K. Xu, Z. Cao, C. Zheng, and L. Liu, "Learning to Search for Vehicle Routing with Multiple Time Windows," *arXiv preprint arXiv:2505.23098*, 2025.